

Лабораторная работа №2

Язык Python. Введение в анализ данных

Задача 1 (4 балла). Руководство Китежградского университета Чародейства и Волшебства считает, что аудиторный фонд используется нерационально – для проведения занятий выделены большие аудитории, но многие студенты прогуливают занятия, в результате в аудиториях остается много свободных мест. Чтобы убедиться в этом, было решено по каждой группе на каждой паре отмечать количество присутствующих студентов. Тут выяснилась еще одна проблема – некоторые преподаватели недобросовестно отнеслись к этому поручению, и отмечали иногда явно нереальные значения – то 0 студентов, то в два раза больше, чем вообще есть в группе.

Ваша задача – по имеющимся записям о посещаемости одной группы определить, какая доля всех записей является некорректной.

Некорректными мы будем считать данные, которые сильно отличаются от остальных (в статистике это называется *выбросами*). Более точно алгоритм выглядит так. Пусть у нас есть набор данных, состоящий из N значений. Вначале найдём квартили для этого набора (Q_1 , Q_2 , Q_3 , см. справку ниже). Затем определим разброс квартилей $IQR = Q_3 - Q_1$. Выбросами (некорректными данными) будем считать все значения, которые меньше, чем $Q_1 - 1.5 \cdot IQR$, а также все значения, которые больше, чем $Q_3 + 1.5 \cdot IQR$.

Справка

Квартили – это значения, которые разбивают упорядоченный набор чисел на 4 равных (по количеству чисел) части. Для их нахождения в случае дискретного набора данных используют следующий алгоритм. Вначале найдем вторую квартиль Q_2 (она же – медиана). Отсортируем все числа. Пусть в наборе N значений: $x_1, x_2, \dots, x_N$. Если N нечетное, то Q_2 равно значению, стоящему ровно в середине (то есть $Q_2 = x_{(N+1)/2}$). Если же N четное, то Q_2 равно среднему арифметическому двух чисел, стоящих в середине (то есть $Q_2 = (x_{N/2} + x_{N/2+1})/2$). После этого разделим упорядоченный набор на две равные половины (если N нечетное, то средний элемент, равный Q_2 , не включается ни в одну из половин). Числа, которые меньше Q_2 , попадут в «нижнюю» половину, а числа, которые больше Q_2 – в «верхнюю». Тогда Q_1 – это медиана «нижней» половины, а Q_3 – медиана «верхней» половины.

Входные данные

В первой строке записано число N – количество пар, на которых отмечалась посещаемость группы, $5 \leq N \leq 1000$.

Далее следует N строк, в каждой записано одно целое число x_i – количество студентов, присутствовавших на i -й паре по мнению преподавателя, $0 \leq x_i \leq 100$.

Выходные данные

Выведите одно целое число – сколько чисел из представленных можно считать некорректными.

Пример

Входные данные	Выходные данные
9 25 24 19 99 18 17 0 21 26	2

Комментарий к примеру

После сортировки получим последовательность чисел: 0, 17, 18, 19, 21, 24, 25, 26, 99. По алгоритму находим $Q_2 = 21$. «Нижняя» половина – это числа 0, 17, 18, 19. Соответственно, $Q_1 = (17+18)/2 = 17.5$. «Верхняя» половина – это числа 24, 25, 26, 99. $Q_3 = (25+26)/2 = 25.5$. Тогда

$IQR = Q3 - Q1 = 25.5 - 17.5 = 8$. Таким образом, некорректными в данной задаче будут считаться значения, которые меньше, чем $17.5 - 1.5 * 8 = 17.5 - 12 = 5$ (такое значение всего одно – число 0), а также которые больше, чем $25.5 + 1.5 * 8 = 25.5 + 12 = 37.5$ (такое значение тоже всего одно – число 99). Итого, всего 2 числа (0 и 99) считаются некорректными.

Задача 2 (4 балла). Компания друзей собралась пойти в поход. Забот и затрат при подготовке похода оказалось много: кто-то закупал еду, кто-то брал в аренду снаряжение, кто-то заказывал транспорт. Когда всё было готово, друзья решили подсчитать, кто сколько денег потратил и, соответственно, кто кому сколько денег должен перевести. Статей расходов оказалось очень много, участников похода было тоже много, поэтому сделать все расчеты вручную оказалось затруднительно.

Напишите программу, которая по информации о том, кто сколько денег потратил, определит: кто, кому и сколько денег должен перевести, чтобы расходы всех участников похода оказались одинаковыми (с точностью до копейки). Количество переводов при этом должно быть как можно меньше.

Входные данные

В первой строке через пробел записаны имена всех участников похода. Имена уникальны, каждое имя состоит из латинских букв. Длина каждого имени – не более 20 символов, количество имен – не более 100.

Во второй строке записано одно целое число N – количество покупок, которое было сделано при подготовке похода.

Далее следует N строк, каждая из которых описывает одну покупку и содержит имя того, кто эту покупку оплачивал, и одно целое число – сумму покупки. Имя и число разделены пробелом. Гарантируется, что имя есть в общем списке участников похода.

Выходные данные

В первой строке выведите одно число M – минимальное количество переводов, которые нужно совершить.

Далее выведите M строк, в каждой указав два имени и вещественное число через пробел: кто, кому и сколько должен перевести. Все суммы переводов должны быть округлены до 2 знаков после запятой. Если существует несколько вариантов переводов, то выведите любой из них – главное, чтобы их количество было минимальным.

Пример

Входные данные	Выходные данные
Ivan Aleksej Igor 3 Ivan 500 Aleksej 100 Ivan 200	2 Aleksej Ivan 166.67 Igor Ivan 266.67

Комментарий к примеру

Иван потратил в сумме 700, но двое остальных переведут ему в сумме 433.34, итого затраты Ивана составят 266.66. Алексей потратил 100 и должен перевести Ивану 166.67, в итоге его затраты составят 266.67. Игорь ничего не потратил на покупки, и все его затраты – это перевод 266.67 Ивану. Таким образом, затраты всех трех друзей окажутся одинаковыми с точностью до копейки. Очевидно, что одним переводом добиться равных затрат не получится, поэтому 2 – это минимальное количество переводов.

Заметим, что такой набор переводов – не единственно возможный. Например, Алексей мог бы перевести 166.67 Игорю, а Игорь перевести Ивану 433.34

Задача 3 (5 баллов). Начинающий предприниматель Александр открыл свою первую пиццерию. Для учета заказов он использует максимально простой инструмент – записывает в блокнот информацию о дате заказа, названии пиццы и стоимости заказа (стоимость одной и той же пиццы даже в один и тот же день может быть разной – это зависит от дополнительных ингредиентов, которые пожелал добавить клиент, но которые Александр в своем блокноте никак не учитывает). По прошествии нескольких дней Александр хочет извлечь из своих записей какую-нибудь полезную информацию. Напишите программу, которая будет выводить:

а) список всех пицц с указанием, сколько раз их заказывали; список должен быть отсортирован по убыванию количества заказов, то есть первой в списке должна оказаться самая популярная пицца;

б) список всех дат с указанием суммарной стоимости проданных в этот день пицц; список должен быть отсортирован хронологически;

в) информацию о самом дорогом заказе;

г) среднюю стоимость заказа (среднее арифметическое по всем стоимостям).

Поскольку исходный текстовый файл заполняется вручную, то формат данных может быть разным (даже в рамках одного файла). Гарантируется только, что каждая строка файла содержит информацию об одном заказе, и в каждой строке указаны 3 значения: дата, название и стоимость. Нужно учесть следующие варианты:

- значения могут быть разделены запятой, точкой с запятой или просто пробелом;
- в дате дата, месяц и год могут быть разделены точкой или косой чертой (/);
- название пиццы может быть указано в кавычках или без них;
- стоимость может быть целым или дробным числом (если число дробное, то в нем не более 2 знаков в дробной части, при этом дробная часть от целой может быть отделена точкой или запятой).

Если строка не соответствует указанному формату (с учетом указанных вариантов), то такую строку нужно пропускать.

Если строка разбивается на части неоднозначно (такое возможно только в крайне редком случае, если название пиццы содержит цифры в конце, а в качестве разделителя используется запятая), то считать стоимостью последние два числа (как одно дробное число), а остальное считать названием пиццы.

Пример входного текстового файла:

```
28.02.2026 Пепперони 420
28.02.2026 Гавайская 440
01.03.2026 Пепперони 430.50
01.03.2026 Четыре сыра 399.99
02.03.2026 Пепперони 400
27.02.2026;Четыре сыра;388,80
28.02.2026 "Четыре сыра" 399,99
20/02/2026,Баварская,440.00
424242 аааа уф
21.02.2026,Гавайская,399.90
03.03.2026 "Баварская" 480
01.04.2026,Акция! Все по 99,99,99,99
28/02/2026 Пепперони 435
```

Пример результата:

```
а)
Пепперони - 4
Четыре сыра - 3
Гавайская - 2
Баварская - 2
Акция! Все по 99,99 - 1
б)
20.02.2026 440.00
```

```
21.02.2026 399.90
27.02.2026 388.80
28.02.2026 1694.99
01.03.2026 830.49
02.03.2026 400
03.03.2026 480
01.04.2026 99.99
в)
03.03.2025 Баварская 480
г)
394.51
```

Задача 4 (3 балла). Файл mbox.txt содержит метаданные почтового сервера. Мы знаем, что строка с адресом автора письма начинается с "From ". Найти адреса всех авторов сообщений и найти того из них, кто пишет больше всех писем.

Исходный файл можно взять по ссылке: <https://www.py4e.com/code3/mbox.txt>

Для создания локальной программы вы можете загрузить файл себе на компьютер. Либо можно выполнять это задание в Jupyter Notebook. Для загрузки данных можно использовать следующий код:

```
# импортируем библиотеку для доступа к файлам в интернете
import requests
# в переменной mbox хранится текст для работы
mbox = requests.get('https://www.py4e.com/code3/mbox.txt').text

# преобразуем текст в список, где каждый объект – это одна строка в файле
all_lines = mbox.split('\n')
```